



Proyecto **MORA**

Monitoreo y Optimización de Recursos Agrícolas

Santiago Cano Molina - Lorena López Bedoya - Jorge
Omar Osorio Velásquez - Federico Loaiza Flórez -
Stiven Alexander Londoño Chavarría

Tabla de contenidos

Tabla de contenidos	2
Resumen	4
Contexto y problema	4
Problema	5
Justificación	5
Alcance y supuestos de datos	6
Actores y uso previsto	6
Preguntas de investigación	6
Riesgos y mitigaciones	7
Criterios de éxito (alto nivel)	7
Objetivo General y Específicos	7
Objetivo general	7
Objetivos específicos	7
Alineación con ODS	8
Alcance y limitaciones	8
Alcance del proyecto	8
Fuera de alcance (exclusiones)	9
Criterios de aceptación	9
Entregables	10
Datos y diccionario (resumen)	10
Fuentes de datos (resumen)	10
Estructura relacional (MySQL) — resumen	10
Campos clave por tabla (resumen)	11
crop_recommendation_n	11
crop_environmental_requirements	11
departamentos_recomendados	11
Diccionario de datos (abreviado)	11
Consultas tipo (ejemplos resumidos)	12
Catálogos y códigos	13
Conexión con visualización y producto	13
Diseño de Base de Datos (DER, PK/FK)	13
Visión general	13
Diagrama Entidad-Relación (DER)	14
Entidades y atributos (resumen)	14
crop_environmental_requirements (catálogo)	14
departamentos_recomendados (geografía)	14
crop_recommendation_n (tabla central)	14
Cardinalidades e integridad	14
Decisiones de diseño	14
Claves primarias y foráneas	15
DDL (fragmentos principales)	15

Verificación de integridad (JOIN de control)	18
Normalización y extensiones	19
Trazabilidad	19
Metodología (ETL, SQL, Análisis)	20
Diseño del pipeline (visión general)	20
ETL: ingesta, limpieza y carga	20
Ingesta	20
Limpieza y normalización	20
Carga a la BD	20
Consultas avanzadas en SQL	21
Muestras y filtros básicos	21
Agregaciones por condiciones de suelo	21
Variabilidad climática por cultivo	21
Enriquecimiento geográfico	22
EDA en Python (perfilamiento y visualización)	22
Perfilamiento y reglas básicas	22
Relaciones suelo - clima	22
PCA (reducción de dimensionalidad)	23
Estandarización y PCA	23
Interpretación	23
Modelos básicos de Machine Learning	23
Regresión (ejemplo: temperatura vs. humedad/lluvia/NPK)	23
Clasificación simple (ejemplo: etiquetas discretas de compatibilidad)	24
Aplicación Streamlit (interacción por rangos)	24
Dashboard en Looker Studio	25
Resultados	25
Resultados de las consultas SQL	25
Rango térmico y orden por humedad	25
Promedios de NPK por cultivo	26
JOIN geográfico	27
Resultados del EDA	27
Distribuciones	27
Comparativas por cultivo	27
Correlaciones	27
Resultados del PCA	27
Modelos básicos de Machine Learning	28
Regresión	28
Clasificación	28
Aplicación en Streamlit	28
Dashboard en Looker Studio	28
Resumen	28
Conclusiones	29
Reproducibilidad y entregables	29
Referencias	29

Resumen

Este informe presenta **MORA**, un prototipo de inteligencia de negocio para la **recomendación de cultivos** a partir de condiciones de **suelo** (N, P, K, pH, humedad) y **clima** (temperatura, precipitación, humedad relativa). El proyecto busca **democratizar** el acceso a analítica práctica para **pequeños y medianos productores**, facilitando decisiones de siembra más informadas y alineadas con la sostenibilidad.

Se integraron **datasets públicos** de referencia agronómica y clima histórico, y se diseñó una **base de datos relacional** (MySQL/SQLite) con tres componentes principales: un **catálogo de requisitos ambientales por cultivo**, una **dimensión geográfica** por departamento y una **tabla central de observaciones**. Sobre esta base se ejecutaron **consultas SQL** para exploración, validación y generación de insumos para análisis.

En **Python**, utilizando **pandas** y **numpy**, se desarrolló un **EDA** con limpieza, perfilamiento y visualización (**matplotlib** y **seaborn**). Se aplicó **PCA** para reducir dimensionalidad e interpretar patrones suelo-clima y se entrenaron **modelos básicos de machine learning** (regresión y clasificación) como línea base interpretativa —no calibración agronómica—. Además, se evaluó la **sensibilidad térmica** observando cómo cambios en **temperaturas mínima y máxima** afectan la compatibilidad de cultivos.

Para la capa de consumo, se implementó una **aplicación interactiva en Streamlit**, que permite filtrar por rangos de variables y visualizar cultivos compatibles, y un **dashboard en Google Looker Studio** con KPIs, comparativas NPK por cultivo y análisis por departamento. El proyecto prioriza la **reproducibilidad** (scripts SQL, notebooks y capturas) y documenta **limitaciones**: no incluye integración IoT en tiempo real ni calibración agronómica avanzada.

Palabras clave: agricultura de precisión, SQL, pandas, PCA, machine learning, Streamlit, Looker Studio, NPK, clima, toma de decisiones.

Contexto y problema

La producción agrícola depende cada vez más de decisiones informadas por datos que integren suelo, clima y manejo del cultivo. Cambios en variables ambientales —en particular, **temperaturas mínima y máxima**, extremos de precipitación y variabilidad intraestacional— impactan la fenología, el rendimiento y la exposición a plagas y enfermedades. En paralelo, la digitalización de registros de campo y la disponibilidad de fuentes públicas de clima e información edáfica facilitan construir **pipelines analíticos reproducibles** que transforman datos heterogéneos en **indicadores operativos y recomendaciones** [Referencia].

En este proyecto (MORA) se consolida una **arquitectura de datos** que integra:

- **Datos de suelo:** N, P, K, pH, humedad y metadatos de muestreo.
- **Datos climáticos:** temperatura (mín./máx.), precipitación y variables derivadas.
- **Metadatos geográficos:** ubicación y, cuando aplica, ciclo/lote/parcela.

Los datos se modelan en una base **relacional (MySQL/SQLite)** para soportar consultas SQL y trazabilidad. Sobre esta base se ejecuta un **EDA** en Python (pandas/numpy), **PCA** para reducción de dimensionalidad y **modelos básicos de machine learning** (regresión/árboles) como líneas base interpretativas. La visualización se publica en dos capas: una **app Streamlit** (exploración guiada y recomendaciones) y un **dashboard en Google Looker Studio** (seguimiento de indicadores y filtros).

Problema

A pesar de contar con mediciones de suelo y acceso a series climáticas, los actores de campo (productores, agrónomos, técnicos) suelen enfrentar:

1. **Fragmentación de la información:** datos en formatos y fuentes dispares que impiden una visión integrada.
2. **Baja reproducibilidad:** ausencia de esquema y **pipeline ETL** formal dificulta repetir análisis y rastrear versiones.
3. **Exploración limitada:** sin EDA sistemático es difícil detectar sesgos, outliers y relaciones latentes suelo-clima.
4. **Desconexión analítica–operativa:** resultados que no se traducen en dashboards o apps que soporten decisiones in situ.
5. **Sensibilidad térmica no cuantificada:** el efecto de cambios en **temperatura mínima y máxima** sobre la recomendación de cultivo se estudia ad-hoc o no se estudia.

Enunciado del problema.

Se requiere un sistema reproducible que integre datos de suelo y clima en una base relacional con analítica estadística y de machine learning (incluido PCA), capaz de evaluar el impacto de los rangos de temperatura mínima y máxima y de entregar visualizaciones y recomendaciones accionables mediante **Streamlit** y **Looker Studio**.

Justificación

Abordar el problema permite:

- **Estandarizar** la captura, limpieza y estructura del dato (diccionario y DDL), reduciendo ambigüedades.
- **Acelerar** el análisis con consultas SQL y EDA reproducible, habilitando inspección iterativa y auditoría.
- **Explicar** variabilidad con **PCA** (patrones latentes suelo-clima) y **modelos básicos de ML** (líneas base interpretables).
- **Operacionalizar** resultados mediante **Streamlit** (interacción por parámetros) y **Looker Studio** (seguimiento y filtros).

Alcance y supuestos de datos

- **Alcance:** integración de datasets de suelo, clima y metadatos; modelado en MySQL/SQLite; ETL; EDA; PCA; líneas base de ML; evaluación exploratoria del rol de temperaturas mín./máx.; publicación en Streamlit y Looker Studio.
- **Supuestos:** calidad mínima de datos (campos obligatorios, unidades consistentes), fechas y ubicaciones válidas; sin imputación agresiva ni feature engineering complejo no documentado.
- **Fuera de alcance:** pronósticos climáticos subdiarios, calibraciones agronómicas específicas por variedad, optimización económica detallada.

Actores y uso previsto

- **Agrónomos y técnicos:** diagnóstico rápido y comparación de lotes/parcelas (dashboards y filtros).
- **Productores:** decisiones sobre recomendación de cultivo bajo rangos térmicos y condiciones de suelo.
- **Equipo analítico:** gobierno del dato, nuevas consultas y experimentos de ML/PCA.

Preguntas de investigación

1. ¿Qué **patrones latentes** (PCA) emergen entre variables de suelo y clima?
2. ¿Cómo cambian las **recomendaciones de cultivo** ante variaciones en **temperaturas mínima y máxima**?
3. ¿Qué **indicadores** (descriptivos y de calidad de dato) deben monitorearse de forma continua en Looker Studio?
4. ¿Qué **líneas base de ML** son más estables e interpretables con el tamaño y la calidad de los datos disponibles?

Riesgos y mitigaciones

- **Datos incompletos/inconsistentes:** controles en ETL, validaciones de esquema y data profiling.
- **Sobreajuste en ML:** validación simple (train/test o holdout) y modelos base interpretables.
- **Mal uso de dashboards:** documentación de definiciones y tooltips con unidades y supuestos.

Criterios de éxito (alto nivel)

- Esquema MySQL/SQLite y **diccionario de datos** consolidados y versionados.
- **EDA reproducible** con hallazgos accionables y trazables.
- **PCA y modelos ML** documentados (métricas base, supuestos).
- **Streamlit y Looker Studio** operativos con filtros y navegación por indicadores.

Nota: sustituye “[Referencia]” por la fuente real (FAO, servicios meteorológicos, publicaciones). Si ya tienes tus referencias en otro documento, agrégalas con la herramienta de citas de Google Docs para formato APA.

Objetivo General y Específicos

Objetivo general

Desarrollar una solución analítica y reproducible para apoyo a la decisión en agricultura de precisión que integre datos de suelo y clima en una base relacional (MySQL/SQLite), ejecute un pipeline de ETL, EDA, PCA y **modelos básicos de machine learning**, y disponibilice resultados a través de una **aplicación interactiva en Streamlit** y un **dashboard en Google Looker Studio** con filtros —incluidos **rangos de temperatura mínima y máxima**— para explorar recomendaciones de cultivo e indicadores operativos.

Objetivos específicos

1. **Modelado y gobierno del dato:** diseñar el **modelo relacional** (DER) con al menos tres tablas interrelacionadas, **claves foráneas** y al menos **una clave primaria compuesta**; definir el **diccionario de datos** y el **DDL** del esquema (SQL).
2. **Integración (ETL):** implementar el **pipeline de extracción, transformación y carga** hacia MySQL/SQLite, normalizando formatos y unidades, y validando campos obligatorios.
3. **Calidad y EDA:** ejecutar **perfilamiento** y **análisis exploratorio** en Python (pandas/numpy) con estadísticas descriptivas, detección de atípicos y visualizaciones (matplotlib/seaborn).
4. **Reducción y estructura latente:** aplicar **PCA** para identificar patrones suelo-clima y evaluar la varianza explicada por componente.
5. **Líneas base de ML:** entrenar y documentar **modelos básicos** (p. ej., regresión lineal y árboles) con validación simple (holdout/train-test), reportando métricas base y supuestos.
6. **Aplicación interactiva:** desplegar una **app en Streamlit** que permita configurar rangos de suelo y clima (incluidas temperaturas mín./máx.) y visualizar resultados y recomendaciones.
7. **Visualización ejecutiva:** construir un **dashboard en Google Looker Studio** con filtros por cultivo, ubicación y periodo, con drill-down a indicadores y fichas de métricas.
8. **Reproducibilidad y entregables:** garantizar **reproducibilidad** (scripts SQL, notebooks, requirements, manual de uso) y consolidar los **entregables** (código fuente, script `.sql` de estructura/población, informe PDF).

Alineación con ODS

- **ODS 2. Hambre Cero:** mejora de decisiones agronómicas basadas en datos.
- **ODS 9. Industria, Innovación e Infraestructura:** arquitectura de datos y analítica reproducible.
- **ODS 12. Producción y Consumo Responsables:** eficiencia en uso de insumos (NPK, agua).
- **ODS 13. Acción por el Clima:** análisis de sensibilidad a temperaturas mínima y máxima.

Alcance y limitaciones

Alcance del proyecto

El **Proyecto MORA** entregará un *prototipo funcional* de analítica y visualización para recomendación/compatibilidad de cultivos, que integra **datos de suelo** (N, P, K, pH, humedad), **datos climáticos** (temperaturas mínima/máxima, precipitación) y **metadatos geográficos** en una arquitectura reproducible. El alcance comprende:

1. **Modelo de datos y gobierno:** diseño del **modelo entidad–relación (DER)** en MySQL con al menos 3 tablas relacionadas, **claves foráneas** y al menos **una clave primaria compuesta**; **diccionario de datos** y **DDL (.sql)** de creación y población.
2. **Integración (ETL):** extracción, transformación y carga hacia MySQL; normalización de unidades, validación de campos obligatorios y controles de calidad.
3. **EDA reproducible:** perfilamiento, estadísticas descriptivas, detección de atípicos y visualizaciones en Python (pandas, numpy, matplotlib, seaborn).
4. **PCA y estructura latente:** reducción de dimensionalidad y análisis de varianza explicada y cargas para identificar patrones suelo–clima.
5. **Modelos básicos de ML:** líneas base interpretables (p. ej., regresión lineal y modelos tipo árbol) con partición *train/test* y reporte de métricas.
6. **Análisis térmico:** evaluación exploratoria del impacto de **temperaturas mínima y máxima** sobre recomendaciones/compatibilidad de cultivos.
7. **Aplicación interactiva (Streamlit):** interfaz para **ingresar rangos** de suelo y clima (incluidas temp. mín./máx.) y explorar resultados.
8. **Dashboard ejecutivo (Looker Studio):** tablero interactivo con filtros por cultivo, ubicación y periodo; KPIs, tarjetas y *drill-down*.
9. **Reproducibilidad y trazabilidad:** repositorio con scripts SQL, notebooks, requirements e **informe técnico**.

Fuera de alcance (exclusiones)

- Integración con **sensores IoT** en tiempo real o despliegues en **hardware** específico.
- **Pronóstico** climático subdiario o modelos espaciotemporales avanzados.
- **Calibraciones agronómicas** por variedad/cultivar o curvas de respuesta a insumos a nivel experimental.
- **Optimización económica** detallada (costeo/ROI logístico-financiero) y planificación operativa de campo.
- **ETL productivo** (orquestración 24/7, SLA de datos, monitorización) y **CI/CD** de analítica.

Criterios de aceptación

1. **Esquema MySQL** con DER, **PK/FK** y al menos **una PK compuesta**; **DDL** y **diccionario** completos.

2. **EDA** reproducible con cuadernos ejecutables y gráficos referenciados.
3. **PCA** documentado (varianza explicada, cargas e interpretación).
4. **ML** entrenado y evaluado (métricas base, supuestos y división de datos).
5. **Streamlit** operativo (parámetros de suelo/clima) y **Looker Studio** con KPIs y filtros.
6. **Informe LaTeX** que compila (pdflatex + biber + pdflatex) con referencias cruzadas y APA.

Entregables

- **Código fuente:** notebooks y scripts.
- **SQL:** DDL del esquema, DML de población y consultas relevantes.
- **Aplicaciones:** Entrenamiento en Machine Learning, Streamlit y dashboard en Looker Studio (enlace/capturas).
- **Informe:** proyecto final (secciones, apéndices, figuras/tablas, bibliografía) y PDF final.

Datos y diccionario (resumen)

Fuentes de datos (resumen)

- **Referencia agronómica por cultivo:** parámetros ideales de suelo y clima (N, P, K, pH, humedad; rangos de temperatura y precipitación) para distintos cultivos.
- **Clima histórico por ubicación:** series/climatologías por ciudad/departamento (temperatura mínima/máxima, precipitación, humedad).

La integración permite contrastar *condiciones observadas* vs. *condiciones de referencia* para soportar la recomendación/compatibilidad de cultivos.

Estructura relacional (MySQL) — resumen

Se emplea un esquema normalizado con claves foráneas y al menos una PK compuesta. Entidades principales:

- `crop_recommendation_n` (tabla central): condiciones (nutrientes y clima) por cultivo y zona.
- `crop_environmental_requirements`: catálogo de requisitos ambientales (rangos óptimos).
- `departamentos_recomendados`: dimensión geográfica para Colombia.

Relaciones:

- `crop_recommendation_n.crop_code` → `crop_environmental_requirements.crop_code` (FK).
- `crop_recommendation_n.depto_code` → `departamentos_recomendados.id_depto` (FK).

Nota: En exploración temprana se usó un esquema alternativo en SQLite (departamento, cultivo, condiciones) para pruebas de carga y consultas.

Campos clave por tabla (resumen)

crop_recommendation_n

- id (FLOAT, PK): identificador del registro.
- N, P, K (FLOAT): macronutrientes del suelo.
- temperature (FLOAT), humidity (FLOAT), rainfall (FLOAT), ph (FLOAT):
- crop (VARCHAR(30)): nombre del cultivo.
- crop_code (INT, FK): código del cultivo (catálogo).
- depto_code (INT, FK), id_depto (INT): claves de departamento.
- departamento_colombia (VARCHAR(30)), zona_vida (INT):

crop_environmental_requirements

- crop_code (INT, PK), crop (VARCHAR(30))
- temperature_min, temperature_max (FLOAT)
- rainfall_min, rainfall_max (FLOAT)

departamentos_recomendados

- id_depto (INT, PK)
- departamento_colombia (VARCHAR(30))

Diccionario de datos (abreviado)

Tabla	Campo	Tipo	Unidad	Descripción
crop_recommendation_n	id	FLOAT	—	Identificador único.
	N, P, K	FLOAT	mg/kg	Macronutrientes (no negativos).
	ph	FLOAT	pH	Rango 0–14 (validar 4–9).

	temperature	FLOAT	°C	Media climatológica.
	humidity	FLOAT	%	Rango 0–100.
	rainfall	FLOAT	mm	Acumulado/media mensual.
	crop	VARCHAR(30)	—	Nombre normalizado.
	crop_code, depto_code	INT	—	FK a catálogos.
<i>crop_environmental_requirements</i>	crop_code	INT	—	PK del cultivo.
	temperature_min/max	FLOAT	°C	Rangos óptimos.
	rainfall_min/max	FLOAT	mm	Rangos óptimos.
<i>departamentos_recomendados</i>	id_depto	INT	—	PK del departamento.
	departamento_colombia	VARCHAR(30)	—	Nombre oficial.

ETL y normalización (resumen)

- **Ingesta:** dos datasets públicos (referencia agronómica por cultivo; clima histórico por ciudad/departamento).
- **Limpieza:** eliminación de duplicados (crop.1, crop_code.1, index); tipificación y normalización de unidades.
- **Modelado:** creación de catálogo de cultivos y dimensión geográfica; enriquecimiento de la tabla central con códigos de cultivo y departamento.
- **Validación:** JOINS de verificación entre tablas; revisión de huérfanos y consistencia de claves.

Consultas tipo (ejemplos resumidos)

```

SELECT * FROM crop_recommendation_n;

SELECT * FROM crop_recommendation_n LIMIT 10;

SELECT N, P, K, crop
FROM crop_recommendation_n
WHERE crop = 'coffee';

SELECT n.crop, n.rainfall, dr.departamento_colombia
FROM crop_recommendation_n n
JOIN departamentos_recomendados dr
  ON n.depto_code = dr.id_depto;

SELECT crop,
       MAX(N) AS max_N,
       MAX(P) AS max_P,
       MAX(K) AS max_K
FROM crop_recommendation_n
WHERE ph BETWEEN 6.0 AND 7.0
GROUP BY crop;

```

Catálogos y códigos

- **Cultivos:** crop_code (PK) vincula el nombre del cultivo con sus requisitos (temperature_min/max, rainfall_min/max).
- **Geografía:** id_depto (PK) y departamento_colombia; depto_code actúa como FK en la tabla central.

Conexión con visualización y producto

- **App Streamlit:** ingreso de rangos de N, P, K, pH, temperaturas mínima/máxima, humedad y precipitación para explorar compatibilidad de cultivos.
- **Dashboard Looker Studio:** filtros por cultivo/departamento/periodo, KPIs y drill-down; mapas y comparativas por departamento.

Diseño de Base de Datos (DER, PK/FK)

Visión general


El esquema relacional integra

El esquema relacional integra **parámetros de suelo y clima** con **catálogos** de cultivo y geografía. La tabla central `crop_recommendation_n` almacena condiciones observadas o derivadas por registro; se conecta por **claves foráneas (FK)** a:

- `crop_environmental_requirements` (catálogo de cultivos y requisitos ambientales), vía `crop_code`
- `departamentos_recomendados` (dimensión geográfica), vía `depto_code` → `id_depto`

Diagrama Entidad-Relación (DER)

Figura 1. DER del esquema lógico (sustituir por la imagen final `fig_der.png`).



Entidades y atributos (resumen)

crop_environmental_requirements (catálogo)

PK: `crop_code` (INT). Atributos: nombre, rangos de temperatura y precipitación óptimos.

departamentos_recomendados (geografía)

PK: `id_depto` (INT). Atributos: `departamento_colombia`, `zona_vida`.

crop_recommendation_n (tabla central)

PK: `id` (AUTOINCREMENT). Medidas: N, P, K, temperatura, humedad, pH, precipitación. FK:

crop_code, depto_code.

Cardinalidades e integridad

- Un cultivo del catálogo vincula múltiples registros observados (1:N).
- Un departamento asocia múltiples observaciones (1:N).
- Integridad referencial garantizada mediante FK hacia catálogos.

Decisiones de diseño

- **PK surrogate:** id AUTOINCREMENT simplifica cargas y trazabilidad.
- **Desnormalización controlada:** campo crop como texto facilita lecturas; clave de negocio en crop_code.
- **Dimensión geográfica:** tabla aislada evita repetición y habilita filtros.

Claves primarias y foráneas

PK: crop_code, id_depto, id

FK: crop_recommendation_n referencia ambos catálogos mediante crop_code y depto_code.

Nota: Para cumplir requisito de PK compuesta, puede añadirse tabla puente cultivo_por_depto(crop_code, id_depto) sin alterar el flujo actual.

DDL (fragmentos principales)

```
-- Catálogo de requisitos ambientales por cultivo
DROP TABLE IF EXISTS crop_environmental_requirements;

CREATE TABLE crop_environmental_requirements (
  crop_code INT NOT NULL,
  crop TEXT NOT NULL,
  temperature_min REAL,
  temperature_max REAL,
  rainfall_min REAL,
  rainfall_max REAL,
  PRIMARY KEY (crop_code)
);

INSERT INTO crop_environmental_requirements
(crop_code, crop, temperature_min, temperature_max, rainfall_min, rainfall_max)
VALUES
(1, 'rice', 20.0, 33.0, 1000.0, 2500.0),
(2, 'maize', 10.0, 40.0, 400.0, 2200.0),
(3, 'chickpea', 20.0, 30.0, 300.0, 700.0),
(4, 'kidneybeans', 18.0, 30.0, 500.0, 1500.0),
(5, 'pigeonpeas', 18.0, 32.0, 400.0, 1000.0),
(6, 'mothbeans', 20.0, 35.0, 200.0, 800.0),
(7, 'mungbean', 22.0, 35.0, 300.0, 900.0),
(8, 'blackgram', 20.0, 35.0, 400.0, 1200.0),
(9, 'lentil', 15.0, 27.0, 300.0, 800.0),
(10, 'pomegranate', 25.0, 35.0, 500.0, 1200.0),
(11, 'banana', 21.0, 35.0, 1200.0, 2500.0),
(12, 'mango', 24.0, 35.0, 750.0, 2500.0),
(13, 'grapes', 15.0, 35.0, 500.0, 1200.0),
(14, 'watermelon', 20.0, 30.0, 400.0, 600.0),
(15, 'muskmelon', 18.0, 30.0, 300.0, 500.0),
(16, 'apple', 6.0, 24.0, 1000.0, 1500.0),
(17, 'orange', 15.0, 30.0, 1000.0, 2000.0),
(18, 'papaya', 22.0, 32.0, 1000.0, 2000.0),
(19, 'coconut', 20.0, 32.0, 1000.0, 3000.0),
(20, 'cotton', 18.0, 35.0, 500.0, 1000.0),
(21, 'jute', 24.0, 38.0, 1500.0, 2500.0),
(22, 'coffee', 15.0, 28.0, 1500.0, 2500.0);
```

Listado 1. Catálogo de requisitos ambientales por cultivo


```

-- Dimensión geográfica de departamentos
DROP TABLE IF EXISTS departamentos_recomendados;

CREATE TABLE departamentos_recomendados (
  id_depto INTEGER PRIMARY KEY,
  departamento_colombia TEXT NOT NULL,
  zona_vida TEXT DEFAULT NULL
);

INSERT INTO departamentos_recomendados (id_depto, departamento_colombia, zona_vida)
VALUES
(1, 'Llanos orientales', 'X'),
(2, 'Cauca', 'X'),
(3, 'Huila', 'X'),
(4, 'Valle del Cauca', 'X'),
(5, 'Meta', 'X'),
(6, 'Boyaca', 'X'),
(7, 'Narino', 'X'),
(8, 'Santander', 'X'),
(9, 'Atlantico', 'X'),
(10, 'Arauca', 'X'),
(11, 'Magdalena', 'X'),
(12, 'Caribe', 'X'),
(13, 'Cundinamarca', 'X');

```

Listado 2. Dimensión geográfica de departamentos

```

-- Tabla central y carga inicial
DROP TABLE IF EXISTS crop_recommendation_n;

CREATE TABLE crop_recommendation_n (
  id INTEGER PRIMARY KEY AUTOINCREMENT,
  N BIGINT,
  P BIGINT,
  K BIGINT,
  temperature FLOAT,
  humidity FLOAT,
  ph FLOAT,
  rainfall FLOAT,
  crop TEXT,
  crop_code INT,
  depto_code INT,
  FOREIGN KEY (crop_code) REFERENCES crop_environmental_requirements(crop_code),
  FOREIGN KEY (depto_code) REFERENCES departamentos_recomendados(id_depto)
);

-- Copia desde la tabla fuente original, preservando el original
INSERT INTO crop_recommendation_n
(N, P, K, temperature, humidity, ph, rainfall, crop)
SELECT N, P, K, temperature, humidity, ph, rainfall, label

```

```
FROM crop_recommendation;
```

Listado 3. Tabla central y carga inicial

```
-- Enriquecimiento con claves foráneas
-- Vincular códigos de cultivo (FK)
UPDATE crop_recommendation_n
SET crop_code = (
    SELECT cer.crop_code
    FROM crop_environmental_requirements AS cer
    WHERE crop_recommendation_n.crop = cer.crop
);

-- Asignar códigos de departamento (FK) según cultivo (regla de negocio)
UPDATE crop_recommendation_n
SET depto_code = (
    CASE
        WHEN crop = 'rice' THEN 1
        WHEN crop = 'maize' THEN 1
        WHEN crop = 'chickpea' THEN 2
        WHEN crop = 'kidneybeans' THEN 3
        WHEN crop = 'watermelon' THEN 5
        WHEN crop = 'apple' THEN 6
        WHEN crop = 'orange' THEN 8
        WHEN crop = 'pigeonpeas' THEN 9
        WHEN crop = 'mothbeans' THEN 7
        WHEN crop = 'blackgram' THEN 7
        WHEN crop = 'banana' THEN 10
        WHEN crop = 'mango' THEN 13
        WHEN crop = 'grapes' THEN 4
        WHEN crop = 'papaya' THEN 2
        WHEN crop = 'coconut' THEN 11
        WHEN crop = 'cotton' THEN 12
        WHEN crop = 'coffee' THEN 3
    END
);
```

Listado 4. Enriquecimiento con claves foráneas

Verificación de integridad (JOIN de control)

```
-- Verificación FK: cultivo y requisitos ambientales
SELECT n.id, cer.crop, n.N, cer.rainfall_min
FROM crop_recommendation_n AS n
JOIN crop_environmental_requirements AS cer
    ON n.crop_code = cer.crop_code;
```

Listado 5. Verificación FK: cultivo y requisitos ambientales

```
-- Verificación FK: departamento asociado
SELECT n.crop, n.N, n.P, n.K, dr.departamento_colombia
FROM crop_recommendation_n AS n
JOIN departamentos_recomendados AS dr
  ON n.depto_code = dr.id_depto;
```

Listado 6. Verificación FK: departamento asociado

```
-- Exportación consolidada para CSV o BI
SELECT *
FROM crop_recommendation_n AS n
JOIN departamentos_recomendados AS dr
  ON n.depto_code = dr.id_depto
JOIN crop_environmental_requirements AS cer
  ON n.crop_code = cer.crop_code;
```

Listado 7. Exportación consolidada para CSV o BI

Normalización y extensiones

El diseño mantiene catálogos y dimensiones separadas, evitando redundancia en descriptores (crop, departamento_colombia) y centralizando reglas (temperature_min/max, rainfall_min/max). Como extensión:

- Definir una tabla puente cultivo_por_depto con PK compuesta (crop_code, id_depto) para métricas por par cultivo-departamento.
- Incorporar índices por crop_code, depto_code y/o crop si el volumen crece significativamente.

Trazabilidad

El DDL completo y el material de población se incluyen en el Apéndice C. Las consultas de validación y ejemplos de análisis se referencian en el Apéndice B (SQL) y el Apéndice D (evidencias de visualización).

Metodología (ETL, SQL, Análisis)

Diseño del pipeline (visión general)

El proyecto implementó un pipeline reproducible que va desde la ingesta de datos hasta la exposición en aplicaciones:

1. Ingesta de dos fuentes: referencia agronómica por cultivo y clima histórico por ubicación.
2. Limpieza y normalización (tipos, unidades, duplicados, valores faltantes).
3. Modelado relacional en MySQL/SQLite (ver Cap. 06: Diseño de BD): tablas de catálogos y tabla central.
4. EDA y transformaciones en Python; generación de tablas consolidadas.
5. Análisis (PCA y modelos de ML básicos) y sensibilidad térmica (temperaturas mínima/máxima).
6. Exposición en Streamlit (interacción por rangos) y Looker Studio (KPIs y filtros).

ETL: ingesta, limpieza y carga

Ingesta

- **Referencia agronómica:** catálogo con parámetros ideales por cultivo (N, P, K, pH; rangos de temperature_min/max y rainfall_min/max).
- **Clima histórico:** climatologías por ciudad/departamento (temperaturas mínima/máxima, precipitación, humedad).

Limpieza y normalización

- Eliminación de columnas duplicadas (crop.1, crop_code.1, index).
- Tipificación consistente (FLOAT/REAL para medidas, INT para códigos).
- Unificación de unidades: °C (temperatura), mm (precipitación), % (humedad), mg/kg (NPK).
- Reglas de validación: pH en 0–14; humedad en 0–100; detección de atípicos por IQR.

Carga a la BD

La carga se realizó con DDL/INSERT en catálogos y tabla central (Cap. 06). Ejemplo (extracto):

```
-- Carga y enriquecimiento con FKs (extracto)
INSERT INTO crop_recommendation_n (N,P,K,temperature,humidity,ph,rainfall,crop)
SELECT N,P,K,temperature,humidity,ph,rainfall,label
FROM crop_recommendation;

UPDATE crop_recommendation_n AS n
SET crop_code = (
  SELECT cer.crop_code
  FROM crop_environmental_requirements cer
  WHERE n.crop = cer.crop
);
```

Listado 1. Carga y enriquecimiento con FKs (extracto)

Consultas avanzadas en SQL

Se diseñó un conjunto de consultas para exploración y validación.

Muestras y filtros básicos

```
-- Muestra acotada y filtro por cultivo
SELECT * FROM crop_recommendation_n LIMIT 10;

SELECT N, P, K, crop
FROM crop_recommendation_n
WHERE crop = 'coffee';
```

Listado 2. Muestra acotada y filtro por cultivo

Agregaciones por condiciones de suelo

```
-- Agregación condicionada por pH
SELECT crop,
       MAX(N) AS max_N,
       MAX(P) AS max_P,
       MAX(K) AS max_K
FROM crop_recommendation_n
WHERE ph BETWEEN 6.0 AND 7.0
GROUP BY crop;
```

Listado 3. Agregación condicionada por pH

Variabilidad climática por cultivo

```
-- Rango y promedio de precipitación por cultivo
SELECT crop,
       MAX(rainfall) - MIN(rainfall) AS rango_lluvia,
       ROUND(AVG(rainfall), 2)      AS prom_lluvia
FROM crop_recommendation_n
GROUP BY crop
ORDER BY rango_lluvia DESC
LIMIT 5;
```

Listado 4. Rango y promedio de precipitación por cultivo

Enriquecimiento geográfico

```
-- JOIN con dimensión geográfica
SELECT n.crop,
       n.rainfall,
       dr.departamento_colombia
FROM crop_recommendation_n n
JOIN departamentos_recomendados dr
  ON n.depto_code = dr.id_depto;
```

Listado 5. JOIN con dimensión geográfica

EDA en Python (perfilamiento y visualización)

Perfilamiento y reglas básicas

```
import pandas as pd
df = pd.read_csv("data/crop_recommendation_unida.csv")

# Tipos y faltantes
perfil = pd.DataFrame({
    "dtype": df.dtypes.astype(str),
    "na_ratio": df.isna().mean().round(3)
})

# Reglas simples
df = df.query("0 <= ph <= 14 and 0 <= humidity <= 100")
df = df[(df['N'] >= 0) & (df['P'] >= 0) & (df['K'] >= 0)]
```

Listado 6. Perfilamiento de columnas y reglas simples

Relaciones suelo - clima

```
corr = df[["N", "P", "K", "temperature", "humidity", "ph", "rainfall"]].corr()

# Ejemplo de gráfico: dispersión humedad vs. temperatura
import matplotlib.pyplot as plt
plt.figure()
plt.scatter(df["temperature"], df["humidity"], s=8)
plt.xlabel("Temperatura (°C)")
plt.ylabel("Humedad (%)")
plt.tight_layout()
```

Listado 7. Correlaciones y gráfico básico

PCA (reducción de dimensionalidad)

Estandarización y ajuste del modelo

Previo al análisis de componentes principales (PCA), se normalizaron las variables continuas del dataset (N, P, K, humidity, ph) utilizando z-score mediante StandardScaler, garantizando comparabilidad entre magnitudes con unidades distintas (mg/kg, %, y pH sin dimensión). El PCA se ejecutó con el paquete FactoMineR en R, especificando el campo crop como variable cualitativa suplementaria, lo que permitió proyectar los cultivos en el espacio definido por los componentes cuantitativos. El modelo retuvo cinco componentes principales para evaluar la distribución de la varianza y definir el punto de corte más representativo según el criterio del “codo”. Los dos primeros componentes concentran la mayor proporción de la información relevante del conjunto de datos.

Varianza explicada

El gráfico de varianza explicada muestra que el primer componente (PC1) concentra el 39,8 % de la variabilidad total, mientras que el segundo (PC2) explica un 24,4 % adicional. En conjunto, ambos capturan aproximadamente el 64,2 % de la varianza total, nivel considerado suficiente para un análisis exploratorio robusto y visualmente interpretable. El comportamiento descendente a partir del segundo componente confirma el criterio del “codo” y valida la selección de dos dimensiones como óptima para la interpretación, evitando redundancia y sobreajuste.

Contribución de las variables

El Componente 1 (Dim1) agrupa las variables P (fósforo) y K (potasio), con contribuciones de 41 % y 42 % respectivamente, seguidas por una menor participación de N (10 %) y pH (7 %). Este eje puede interpretarse como un factor químico del suelo, pues resume la variabilidad asociada a los macronutrientes minerales que determinan la fertilidad.

El Componente 2 (Dim2) está fuertemente dominado por la humedad (≈ 58 %), complementado en menor grado por el nitrógeno (≈ 33 %). En este sentido, la segunda dimensión representa un factor hidrológico, asociado a la disponibilidad de agua y condiciones de microclima que influyen en la

viabilidad de cada cultivo. El pH y el fósforo tienen baja contribución a este eje, indicando una menor influencia en la variabilidad vertical del plano factorial.

Interpretación del biplot

El biplot permite visualizar simultáneamente las observaciones (cultivos) y los vectores de las variables cuantitativas.

- Eje horizontal (Dim1, 39,8 %): diferencia cultivos según su contenido de fósforo (P) y potasio (K), mostrando hacia la derecha agrupamientos de cultivos con mayores concentraciones de estos nutrientes, como manzana y uva, ambos asociados a suelos más ácidos y con baja concentración de nitrógeno.

- Eje vertical (Dim2, 24,4 %): refleja un gradiente de humedad. En la parte superior se ubican cultivos como banano y papaya, que requieren suelos más húmedos y muestran también mayor contenido de nitrógeno, mientras que hacia la parte inferior predominan especies adaptadas a condiciones más secas, como garbanzo, gandúl y frijol rojo.

Adicionalmente, se observa un tercer subconjunto con cultivos de clima templado o básicos en pH, como café, naranja, maíz y coco, posicionados hacia el extremo izquierdo del plano, lo que sugiere su dependencia de suelos con alto contenido de nitrógeno y pH más alcalino.

Síntesis interpretativa

El PCA permitió reducir la dimensionalidad de cinco variables cuantitativas a dos ejes conceptuales de interpretación agronómica clara:

1. Eje químico (PC1): controlado por la fertilidad mineral del suelo (P y K).
2. Eje hidrológico (PC2): determinado por la disponibilidad de humedad y nitrógeno.

Este resultado evidencia que la variabilidad edáfica de los cultivos analizados puede describirse principalmente a partir de la interacción entre la fertilidad química y las condiciones de humedad, lo que respalda la pertinencia del PCA como herramienta exploratoria dentro del flujo de análisis del proyecto MORA.

Modelo de Machine Learning

Objetivo

Aprender un clasificador multiclase que, a partir de predictores edáficos-climáticos, estime el **código de cultivo (`crop_code`)** para soportar la recomendación operativa.

Datos y variables

Se parte del dataset unificado. Se eliminan campos no predictivos ni categóricos redundantes (`crop`, geografía y rangos de referencia), quedando **8 predictores numéricos** derivados de suelo y clima. La **etiqueta** es `crop_code` (clases discretas de cultivos). La columna `rainfall` se normaliza de texto a número reemplazando coma decimal por punto y convirtiendo a `float`.

Partición de datos

Se divide el conjunto en **entrenamiento** y **prueba** con `train_test_split (50/50, random_state=1)`. No se usa *cross-validation* porque el objetivo es una línea base reproducible.

Preprocesamiento

1. **Estandarización** con `StandardScaler` ajustado **solo** en entrenamiento y aplicado a prueba.
2. **Escalado min-max** a 0,10,10,1 con `MinMaxScaler` para algoritmos sensibles a distancias (KNN).
3. Todas las transformaciones se encadenan en el orden anterior para evitar fuga de información.

Modelos evaluados

- **K-Nearest Neighbors (K=5)**: referencia basada en distancia euclídea sobre variables escaladas.
- **Naive Bayes Gaussiano**: supuestos de normalidad y condicional independencia.
- **Análisis Discriminante Lineal (LDA)**: fronteras lineales con proyección supervisada.
- **Regresión Logística (multiclase, *one-vs-rest*)**: base lineal con regularización por defecto.

Métricas y validación

Para cada modelo se calculan en el *hold-out* de prueba:

- **Accuracy**.
- **Precision, Recall y F1-macro** para ponderar por clase de forma uniforme.
- **Matriz de confusión** para inspección de errores y confusiones entre cultivos.

Persistencia y uso

El mejor modelo por F1-macro se serializa con `joblib.dump (modelo_entrenado.pkl)`.

Se construye una **GUI en Tkinter** que:

1. recibe entradas numéricas del usuario (N, P, K, temperatura, humedad, pH, lluvia),
2. aplica el mismo *pipeline* de escalado,
3. invoca `predict` y

4. mapea el **crop_code** a su **nombre de cultivo** para la respuesta.

Control de calidad

- Verificación de tipos y rangos antes de predecir; advertencias si faltan valores.
- Revisión manual de falsos positivos/negativos impresos durante pruebas para depurar el mapeo de clases en la interfaz.

Recomendaciones para iteraciones posteriores

- Sustituir el *split* 50/50 por **validación cruzada estratificada**.
- Incorporar **balanceo por clase** o *class weights* si hay desbalance.
- Empaquetar el flujo en un **Pipeline de scikit-learn** para asegurar el mismo preprocesamiento en entrenamiento y despliegue.
- Explorar **árboles/boosting** y **features** derivados de PCA si se busca mayor desempeño manteniendo interpretabilidad.

Aplicación Streamlit (interacción por rangos)

Objetivo

Permitir que el usuario simula condiciones **NPK + clima** y obtenga una **ubicación óptima** (Departamento + Zona de vida) con alternativas y niveles de confianza, usando el clasificador entrenado.

Informe Detallado_ Modelo de Pr...

Flujo general

1. **Carga y preprocesamiento:** el *backend* lee el dataset, crea **target_location = departamento_colombia + " / " + zona_vida**, codifica **crop** y **target** con *LabelEncoder*, y conserva las columnas predictoras.
2. **Modelo:** **RandomForestClassifier** con **n_estimators=150**, **max_depth=15** entrenado con **80/20 train/test**.
3. **Interfaz:** sliders en la barra lateral generan un vector de condiciones futuras y disparan **predict** y **predict_proba**.

4. **Salida:** ubicación más probable, **Top-5** alternativas con probabilidad, y gráfico 3D de sensibilidad térmica (T° mín–máx).

Entradas en la UI

- **Cultivo:** selector; al elegirlo, la app calcula promedios históricos para inicializar sliders.
- **Sliders:** `N`, `P`, `K`, `temperature`, `temperature_min`, `temperature_max`.
- (Opcional) Campos numéricos para edición precisa; *tooltips* con unidades.

Lógica de predicción

- **Vector futuro:** `[[N, P, K, temperature, temperature_min, temperature_max, crop_encoded]]`.
- **Predicción principal:** `predict(...)` → `target_location`.
- **Confianza y alternativas:** `predict_proba(...)` → Top-5 ubicaciones con porcentaje.
- **Sensibilidad térmica:** malla 2D variando `temperature_min` y `temperature_max` con NPK fijos; la probabilidad del *top-1* se visualiza como **superficie 3D** que delimita la zona de confort térmica.

Validación y control

- Imputación simple de faltantes por media en columnas numéricas.
- Verificación de rangos: `0–14` pH, `0–100` humedad si se incluye, límites razonables para NPK.
- Semilla fija para reproducibilidad (`random_state=42`).
- Métricas de prueba visibles en una sección de “Diagnóstico” (accuracy y matriz de confusión).

Consideraciones de UX

- Valores iniciales “sensatos” por cultivo, texto de ayuda por variable, y botones **Reset** y **Guardar escenario**.

- Accesibilidad: unidades en etiquetas y colores con contraste suficiente.

Despliegue

- *Single file app* (`streamlit run app_futuro.py`).
- Versionado del modelo y *encoders* junto a la app (`model.pkl`, `label_encoders.pkl`).
- Cache de datos con `@st.cache_data` y del modelo con `@st.cache_resource`.

Dashboard en Looker Studio

Objetivo

Construir un tablero reproducible que integre **suelo y clima** para explorar compatibilidad de cultivos por **departamento/zona**, con filtros, KPIs y visualizaciones accionables.

Fuente y modelo de datos

1. **Conector:** Google Sheets o CSV en Drive; alternativa BigQuery si el volumen crece.
2. **Vista lógica:** una tabla “hechos” con medidas (N, P, K, `temperature`, `humidity`, `ph`, `rainfall`) y descriptores (`crop`, `crop_code`, `departamento_colombia`, `zona_vida`, `Latitud`, `Longitud`).
3. **Tipos:** numéricos como *Number*; `ph` sin unidad; `humidity` como *Percent*; geografía como *Geo* → *Latitude/Longitude* y *Region* → *Colombia* → *Department*.

Campos calculados (en Looker Studio)

- `target_location = departamento_colombia || " / " || zona_vida`
- `NPK_total = N + P + K`
- `temp_bin = CASE WHEN temperature < 20 THEN "Baja" WHEN temperature < 28 THEN "Media" ELSE "Alta" END`
- `compat_score` (proxy simple) = $0.4 * \text{norm}(P) + 0.4 * \text{norm}(K) + 0.2 * \text{norm}(\text{humidity})$ donde `norm(x)` es reescalado min-max por campo.
- `tooltip_geo = crop || " | T:" || ROUND(temperature,1) || "°C | H:" || ROUND(humidity,0) || "% | NPK:" || NPK_total`

Nota: si usas BigQuery, crea estos campos en SQL para mejor rendimiento.

Páginas del tablero

1. **Portada:** descripción breve del proyecto y navegación.
2. **Caracterización climática:** dispersión *rainfall-temperature*, combo *rainfall vs (K,P)*, barras apiladas **N/P/K por cultivo**.
3. **Distribución geográfica:** mapa de burbujas por departamento y *lat/long*, **treemap** por *departamento_colombia × crop*, **gauge** de registros.

Componentes y configuración

A. Filtros y controles

- Filtros globales: *crop*, *departamento_colombia*, *temp_bin*.
- Rango numérico para *ph*, *humidity* y *rainfall*.
- Botón “Reset” (control de parámetro o enlace a URL con *?rf=all*).

B. Gráficos

- **Dispersión:** *X rainfall*, *Y temperature*, color por *crop*, tamaño por *humidity*.
- **Combo:** barras **K** y **P** por *crop*; línea *rainfall* (eje secundario).
- **Barras apiladas:** **N**, **P**, **K** por *crop* ordenadas por *NPK_total*.
- **Mapa:** geodimensión por *departamento_colombia + lat/long*; color por *temperature*, tamaño por *rainfall*; *tooltip = tooltip_geo*.
- **Treemap:** dimensión principal *departamento_colombia*, secundaria *crop*; métrica *COUNT_DISTINCT(crop_code)* o *COUNT(*)*.
- **Gauge:** métrica *COUNT(*)* con meta configurable.
Resultados

Resultados de las consultas SQL

A partir del esquema descrito en el Cap. 06, se ejecutaron consultas de exploración y validación que generaron salidas reutilizadas en el EDA y los tableros.

Rango térmico y orden por humedad

Se filtraron registros con temperature en el rango (25, 30) (°C) y se ordenó por humidity de mayor a menor para identificar cultivos más exigentes en humedad dentro del intervalo térmico.

```
-- Condición de temperatura y orden por humedad
SELECT crop, temperature, humidity
FROM crop_recommendation_n
WHERE temperature > 25 AND temperature < 30
ORDER BY humidity DESC;
```

Listado 1. Condición de temperatura y orden por humedad

Cultivo	Temperature (°C)	Humidity (%)
[pendiente_cultivo]	27.1	88
[pendiente_cultivo]	26.4	85
[pendiente_cultivo]	29.3	82

Tabla 1. Top cultivos por humedad en 25–30 °C (extracto).

Promedios de NPK por cultivo

Se agregaron los macronutrientes por crop para obtener una referencia de requerimientos medios.

```
-- Promedios NPK por cultivo
SELECT crop,
       AVG(N) AS avg_N,
       AVG(P) AS avg_P,
       AVG(K) AS avg_K
FROM crop_recommendation_n
GROUP BY crop
ORDER BY crop;
```

Listado 2. Promedios NPK por cultivo

Cultivo	avg_N	avg_P	avg_K
coffee	—	—	—
rice	—	—	—
maize	—	—	—

Tabla 2. Promedios de N, P y K por cultivo (extracto).

JOIN geográfico

La integración con departamentos_recomendados permitió mostrar las combinaciones cultivo–departamento y validar cobertura geográfica.

```
-- Cultivo con departamento asociado
SELECT n.crop, dr.departamento_colombia, AVG(n.temperature) AS t_med, AVG(n.rainfall) AS
rain_med
FROM crop_recommendation_n n
JOIN departamentos_recomendados dr
ON n.depto_code = dr.id_depto
GROUP BY n.crop, dr.departamento_colombia;
```

Listado 3. Cultivo con departamento asociado

Resultados del EDA

Se consolidaron hallazgos exploratorios a partir de distribuciones, comparativas y correlaciones.

Distribuciones

- Histograma de pH: distribución con concentración en el intervalo agronómico más frecuente.
- Histogramas de temperatura y humedad: permiten identificar colas y posibles atípicos.



Comparativas por cultivo



- Boxplots de temperatura por cultivo: variabilidad intra-cultivo y presencia de valores extremos.
- Barras agrupadas NPK por cultivo: diferencias de requerimiento promedio.

Correlaciones

· Matriz de correlación (suelo-clima): asociaciones entre N, P, K, temperature, humidity, ph, rainfall.

Resultados del PCA





Varianza explicada. PC1 explica 39,8 % y PC2 24,4 % de la varianza; juntos suman 64,2 %. PC3 añade 18,6 % (acumulado 82,8 %). El gráfico de “codo” respalda trabajar con 2 componentes para interpretación visual y, si se requiere mayor cobertura, 3 componentes para análisis numérico.

Contribuciones por componente.

- **PC1 (eje químico):** dominado por K ≈ 42 % y P ≈ 41 %; aportes menores de N ≈ 10 %, pH ≈ 7 % y humedad ≈ 1 %. Interpretable como fertilidad mineral del suelo.
- **PC2 (eje hidrológico):** dominado por humedad ≈ 58 %, seguido de N ≈ 33 %; contribuciones bajas de K ≈ 6 %, pH ≈ 5 % y P $\approx 0-1$ %. Representa disponibilidad hídrica y efecto asociado de nitrógeno.

Estructura PC1–PC2 (biplot).

- **Derecha (PC1 alto):** cultivos con P y K altos; destacan manzana y uva. Suelos más ácidos y N relativamente bajo.
- **Arriba (PC2 alto):** cultivos exigentes en humedad y con N mayor; sobresalen banano y papaya.
- **Izquierda (PC1 bajo):** grupo amplio con P y N bajos; dentro de él coexisten suelos más secos (p. ej., frijol rojo, garbanzo, gandúl, mango) y más húmedos (algodón, sandía, arroz).
- **pH básico y N alto:** café, naranja, maíz, coco se ubican hacia la zona izquierda, coherente con pH más alcalino y mayor N.

Hallazgos clave.

1. La variabilidad entre cultivos se resume en dos gradientes: fertilidad mineral (P–K) y condición hídrica (humedad) con efecto de N.
2. Los clusters observados en el biplot son consistentes con requerimientos agronómicos conocidos: frutales templados con altos P–K; tropicales húmedos con N alto; leguminosas y cucurbitáceas con perfiles más secos y bajos en P–N.
3. Para tareas de clasificación o recomendación, P, K, humedad y N son los predictores más informativos; pH actúa como modulador secundario.

Implicaciones operativas.

- Priorizar monitoreo y manejo de P, K y humedad en la toma de decisiones.
- Usar PC1 y PC2 como features derivados en modelos base, o 3 PCs si se busca >80 % de varianza explicada.
- Emplear los vectores del biplot para definir umbrales prácticos por cultivo en la app y el dashboard.

Resultados del Modelos de Machine Learning

Configuración. Conjunto dividido 50/50 en entrenamiento y prueba. Escalado **StandardScaler** + **MinMaxScaler**. Modelos evaluados: **KNN (k=5)**, **Naive Bayes Gaussiano**, **LDA** y **Regresión Logística**. Métricas en prueba: *accuracy*, *precision*, *recall* y **F1-macro** con matriz de confusión.

Desempeño comparado.

- **Regresión Logística** obtuvo el **mejor F1-macro** y fue el modelo seleccionado para despliegue (`modelo_entrenado.pkl`).
- **LDA** quedó muy cerca del líder y superó a **KNN** en clases con superposición.
- **Naive Bayes** presentó el menor desempeño por violar supuestos de normalidad/independencia en varias variables.

Matriz de confusión. Los errores se concentran en pares de cultivos con perfiles cercanos:

- Frutales templados con **alto P-K**: *uva* ↔ *manzana*.
- Tropicales húmedos con **N alto**: *banano* ↔ *papaya*.
- Leguminosas y granos con **P y N bajos**: *garbanzo* ↔ *frijol rojo* ↔ *gandúl*.
Esto indica fronteras cercanas en el subespacio dominado por P, K, humedad y N.

Prueba funcional (GUI). Con la interfaz Tkinter y el modelo serializado:

- Entrada ejemplo: **N=48, P=63, K=43, temp=28 °C, humedad=40 %, pH=7, lluvia=210 mm**.
- Salida: **“el mejor cultivo es uvas”**.
La predicción es consistente con el eje químico identificado en el PCA (P-K altos).


Hallazgos clave.

1. **P, K, humedad y N** son los predictores más influyentes; **pH** actúa como modulador.
2. El modelo lineal generaliza mejor que KNN en presencia de variables escaladas y clases parcialmente solapadas.
3. La combinación **PCA + LR** es viable: los dos primeros componentes pueden servir como *features* derivados sin pérdida relevante de señal.

Siguientes pasos.

- Validación cruzada y **curvas de aprendizaje**.
- Pipeline único (**Pipeline**) con escalado y clasificador para evitar variaciones.
- Ensayo con **árboles/boosting** y ajuste de umbrales por clase.

- Reporte automatizado de métricas y *feature importance* para el tablero.



Entrada de datos

Datos de entrada


Nitroso	Fosforo	Potasio	temperatura
48	63	43	28
humidity	PH	precipitación	
40	7	210	

respuesta:Segun los datos digitados el mejor cultivo es uvas

predecir

Aplicación en Streamlit





Condiciones Climáticas

Temp. Min. (°C)

22,01

Humedad Min. (%)

14,26

Temp. Máx. (°C)

50,00

Humedad Máx. (%)

80,98

Precipitación Min. (mm)

10,01

-

+

Precipitación Máx. (mm)

60,00

-

+

Detalle de las Probabilidades

	Cultivo	Probabilidad (%)
0	coffee	50.0%
1	banana	10.0%
2	mango	10.0%
3	maize	10.0%
4	rice	10.0%
5	watermelon	6.7%
6	pigeonpeas	1.3%
7	papaya	1.3%
8	orange	0.7%

Dashboard en Looker Studio



TIC



TALENTO
TECH



Aprendizaje
Interactivo





Proyecto
MORA

El proyecto **Monitoreo y Optimización de Recursos Agrícolas** tiene como objetivo **Desarrollar** una herramienta interactiva basada en inteligencia de negocio y agricultura de precisión que integre datos climáticos y del suelo en tiempo real, con el fin de empoderar a pequeños y medianos agricultores colombianos. El proyecto busca optimizar el uso de recursos, mejorar la productividad, reducir el impacto ambiental y democratizar el acceso a tecnologías avanzadas, promoviendo una agricultura más eficiente, sostenible y alineada con los saberes tradicionales y los Objetivos de Desarrollo Sostenible.

Caracterización climática

Distribución



Conclusiones

1. **Arquitectura de datos lista para producir.** Se integró un esquema relacional con catálogos y dimensión geográfica, ETL reproducible y consultas de control. Soporta trazabilidad, auditoría y consumo por aplicaciones.
2. **Exploración confiable.** El EDA detectó rangos, atípicos y correlaciones suelo-clima. Se estandarizaron unidades y se documentaron reglas básicas de calidad del dato.
3. **Estructura latente clara.** El PCA mostró dos ejes dominantes:
 - **PC1 (39,8 %):** fertilidad mineral, explicado por **P** y **K**.
 - **PC2 (24,4 %):** condición hídrica, dominada por **humedad** y apoyada por **N**.
Con ambos, se explica **64,2 %** de la varianza. Los clusters observados coinciden con requerimientos agronómicos conocidos.

4. **Modelo base funcional.** Entre KNN, Naive Bayes, LDA y Regresión Logística, esta última entregó el mejor F1-macro en *hold-out* y se desplegó como línea base. El patrón de errores se concentra en cultivos con perfiles edáficos cercanos. Predictores de mayor señal: **P, K, humedad y N**; **pH** modulador.
5. **Interacción operativa.**
 - **App Streamlit:** permite simular rangos NPK + clima y obtener recomendaciones bajo un flujo reproducible.
 - **GUI Tkinter:** prueba funcional de predicción local con el modelo serializado.
 - **Dashboard Looker Studio:** navegación por cultivo y territorio con KPIs, mapa y comparativas NPK.
6. **Valor para la decisión.** El sistema prioriza variables accionables (P, K, humedad) y entrega visualizaciones que facilitan comparar escenarios y territorios. Sirve como apoyo inicial para técnicos y productores.
7. **Limitaciones.** Hold-out 50/50 sin validación cruzada, posible desbalance de clases, ausencia de calibración por variedad y manejo, y resolución geográfica a nivel departamental, no de parcela.
8. **Líneas de mejora.**
 - Validación cruzada estratificada y *class weights*.
 - *Pipeline* unificado de *preprocessing* + modelo y registro de versiones.
 - Modelos de árboles/boosting y uso opcional de PCs como *features*.
 - Ampliar cobertura geográfica y variables climáticas; sumar costos y criterios de riesgo.
 - Integración con la app y el tablero para cerrar el ciclo datos→modelo→decisión.

Síntesis. MORA entrega una base técnica coherente: datos limpios y trazables, estructura latente interpretable, modelo clasificatorio utilizable y dos capas de consumo. Es un prototipo listo para iterar que reduce incertidumbre en la recomendación de cultivos y acelera la adopción de analítica en campo.

Reproducibilidad y entregables

Colab Pandas/Dashboards:

<https://colab.research.google.com/drive/1VNIUhZAoboPlOOg6IGybapIA-ZHhodRb?usp=sharing>

Colab PCA:

<https://drive.google.com/file/d/1yXkQ5ncKyUBo7dhSXuAnI9pTFvWBqznM/view?usp=sharing>

Modelo machine learning y App:

<https://github.com/StivLon/Predicci-n-de-cultivos-proyecto-mora>

Dashboard Looker Studio:

https://lookerstudio.google.com/u/0/reporting/48bd8f0d-9c3c-432e-b266-d1195e35bbff/page/p_wta2w7gkwd?s=p82rk1KNTgQ

Github proyecto MORA: https://github.com/florezforest/proyecto_mora/tree/main